Modely

Cíle

- Lineární modelování
- Interpretace modelu

Lineární regrese

Trocha teorie...

$$y_i = \beta_0 + \beta_1 x_{i1} + ... + \beta_p x_{ip} + \epsilon_i$$

V praxi:

```
lm(závislá ~ nezávislá, data
= ...)
```

Práce s modelem

- Shrnutí modelu: summary(model)
- Přehled reziduálů: residuals(model)
- Uplatnění modelu na nová data:

```
predict(model, newdata = ...)
```

Interpretace lineárního modelu

```
Call:
lm(formula = hodnota ~ obdobiod, data = potraviny)
Residuals:
    Min
              10 Median 30
                                       Max
-0.68944 -0.18439 -0.03149 0.17843 0.76785
Coefficients:
            Estimate Std. Error t value Pr(>|t|)
(Intercept) 8.173e-01 1.707e-01 4.789 2.71e-06 ***
obdobiod 6.166e-04 1.152e-05 53.501 < 2e-16 ***
Signif. codes: 0 '***' 0.001 '**' 0.05 '.' 0.1 ' ' 1
Residual standard error: 0.2635 on 284 degrees of freedom
Multiple R-squared: 0.9097, Adjusted R-squared: 0.9094
F-statistic: 2862 on 1 and 284 DF, p-value: < 2.2e-16
```

Nelineární model

 Když na základě dobré teorie vím, že závislost je jiná než lineární (tj. vím jaká, a vím proč)

```
y_t = x_0(1+r)^t

nls(zavisla \sim pocatek * (1 + r)^t,

data = dataset,

start = list(a = 1, r = .01))
```

